Dự đoán Mối Quan hệ Thảo Dược–Bệnh Dựa trên Graph Attention Network với Dual-View Contrastive Learning

Tóm tắt nội dung

Tóm tắt. Việc dự đoán mối quan hệ giữa thảo dược và bệnh (herb–disease association, HDA) đóng vai trò quan trọng trong nghiên cứu y học cổ truyền, giúp khám phá các chỉ định điều trị mới và thúc đẩy quá trình phát triển thuốc. Các phương pháp hiện tại thường chỉ khai thác một loại thông tin đơn lẻ hoặc bỏ qua sự tương đồng sinh học tiềm ẩn giữa các thực thể trong không gian thuốc và bệnh. Bài báo này đề xuất mô hình **GATHDA-DVCL**, kết hợp bốn thành phần chính: (i) Graph Attention Network (GAT) ba lớp để học biểu diễn nút trên đồ thị quan hệ và đồ thị tương tự; (ii) dual-view contrastive learning để đồng chỉnh biểu diễn từ hai góc nhìn đồ thị; (iii) contrastive pair loss để tăng cường khả năng phân biệt cặp dương tính; và (iv) cơ chế fused attention để kết hợp thích nghi hai luồng biểu diễn. Trên bộ dữ liệu TCM gồm 1.008 thảo dược, 10.890 bệnh và 2.342.544 cặp tương tác dương, mô hình đề xuất đạt AUPR = 0,9739 và AUC = 0,9741, vượt trội hơn các phương pháp hiện có trên cùng bộ dữ liệu. Ablation study xác nhận đóng góp rõ ràng của từng thành phần, trong đó dual-view contrastive learning là yếu tố có tác động lớn nhất.

Từ khóa: herb–disease association, graph attention network, contrastive learning, dual-view learning, traditional Chinese medicine.

Mục lục

1 Giới thiệu **3**

2 Dữ liệu **4**

2.1 Nguồn gốc bộ dữ liệu 4

2.2 Cấu trúc và thống kê dữ liệu 4

2.3 Tiền xử lý dữ liệu 5

3 Bài toán và Phương pháp Đề xuất **5**

3.1 Định nghĩa bài toán 5

3.2 Kiến trúc tổng thể 5

3.3 Xây dựng đồ thị 6

3.3.1 Đồ thị tương tác (Adjacency Graph) 6

3.3.2 Đồ thị Tương tự (Similarity Graph) 6

3.4 Mô hình Graph Attention Network 8

3.5 Kết hợp Hai Góc Nhìn với Fused Attention 9

3.6 Tính Điểm Cặp 9

3.7 Hàm Mất mát Tổng hợp 9

3.7.1 Binary Cross-Entropy Loss 9

3.7.2 Contrastive Pair Loss 10

3.7.3 Dual-View Contrastive Loss 10

3.7.4 Hàm Mất mát Tổng hợp 11
3.8 Huấn luyện 11

4 Thực nghiệm và Kết quả **11**
4.1 Cài đặt Thực nghiệm 11
4.1.1 Giao thức đánh giá 11
4.1.2 Siêu tham số 11
4.2 Ablation Study 12
4.3 Tuning Siêu tham số 13
4.4 So sánh với một số phương pháp khác 13
4.5 Đường cong PR và ROC 14
4.6 Phân tích mối tương quan giữa mức độ kết nối và độ tự tin dự đoán 14

5 Kết luận **17**

1. Giới thiệu

Y học cổ truyền Trung Quốc (TCM) đã tích lũy hàng nghìn năm kinh nghiệm điều trị bằng thảo dược, và ngày nay vẫn là nền tảng chăm sóc sức khỏe của hàng tỷ người tại châu Á. Mặc dù vậy, việc làm sáng tỏ cơ chế phức tạp giữa thảo dược và bệnh ở cấp độ phân tử vẫn còn là một thách thức lớn. Mỗi thảo dược chứa hàng trăm hợp chất hóa học (compound), mỗi hợp chất lại tác động lên nhiều protein mục tiêu (target protein), và mỗi protein liên kết với nhiều bệnh thông qua các con đường tín hiệu sinh học. Do đó, không gian tìm kiếm các mối quan hệ thảo dược–bệnh rất rộng lớn, khiến các thí nghiệm ướt (wet-lab) đơn thuần trở nên không khả thi về mặt chi phí và thời gian [1].

Để đối phó với vấn đề này, nhiều phương pháp tính toán dự đoán HDA đã được đề xuất. Các phương pháp dựa trên tương đồng (similarity-based) khai thác độ tương đồng về hợp chất hoặc protein để suy ra mối liên kết mới giữa thảo dược và bệnh [2]. Tuy nhiên, nhóm phương pháp này có hạn chế khi tập dữ liệu thưa thớt và không học được biểu diễn tiềm ẩn đặc trưng. Các phương pháp dựa trên học sâu (deep learning) như mạng nơ-ron tích chập và autoencoder đã được áp dụng để học biểu diễn từ ma trận tương tác [3], song phần lớn chỉ mô hình hóa quan hệ thảo dược–bệnh như bài toán matrix factorization mà không khai thác cấu trúc tô pô của đồ thị sinh học.

Graph Neural Network (GNN) đã chứng minh tiềm năng lớn trong bài toán dự đoán liên kết trên đồ thị sinh học, vì chúng có khả năng tổng hợp thông tin từ các nút lân cận theo cách có cấu trúc [4]. Đặc biệt, Graph Attention Network (GAT) [5] cho phép mô hình học trọng số khác nhau cho các hàng xóm, phù hợp với tính chất không đồng nhất của tương tác sinh học. Tuy nhiên, phần lớn các mô hình GNN hiện có chỉ xây dựng một loại đồ thị duy nhất từ ma trận tương tác, bỏ qua thông tin tương đồng sinh học từ profile hợp chất hay protein. Việc kết hợp nhiều nguồn thông tin dưới dạng đa góc nhìn (multi-view) vẫn chưa được khai thác đầy đủ trong bối cảnh dự đoán HDA.

Contrastive learning [6] đã trở thành một hướng nổi bật trong học biểu diễn, với ý tưởng cốt lõi là kéo gần các cặp dương tính và đẩy xa các cặp âm tính trong không gian đặc trưng. Khi áp dụng lên đồ thị, Graph Contrastive Learning [7] sử dụng các phép tăng cường (augmentation) để tạo ra hai góc nhìn của cùng một đồ thị, sau đó tối đa hóa sự nhất quán của biểu diễn. Ý tưởng này có thể được áp dụng tự nhiên vào bài toán HDA khi ta có hai loại đồ thị khác nhau (đồ thị tương tác và đồ thị tương tự) cùng biểu diễn một không gian nút.

Bài báo này đề xuất mô hình GATHDA-DVCL với các đóng góp chính sau:

(1) Thiết kế kiến trúc dual-view: xây dựng hai loại đồ thị (đồ thị tương tác và đồ thị tương tự kết hợp GIP) và thực hiện encode độc lập bằng GAT ba lớp trên mỗi đồ thị.

(2) Áp dụng dual-view contrastive loss để ép hai luồng biểu diễn từ hai đồ thị nhất quán với nhau ở cấp độ nút, từ đó cải thiện chất lượng embedding.

(3) Áp dụng contrastive pair loss trên các cặp thảo dược–bệnh dương tính trong mini-batch để tăng cường khả năng phân biệt cặp.

(4) Thiết kế cơ chế fused attention thích nghi để kết hợp hai luồng biểu diễn một cách có trọng số theo từng nút thay vì kết hợp cố định.

(5) Thực nghiệm toàn diện trên bộ dữ liệu TCM quy mô lớn, bao gồm ablation study, tuning siêu tham số theo giai đoạn, và so sánh với nhiều phương pháp hiện có.

Phần còn lại của bài báo được tổ chức như sau: Mục 2 mô tả bộ dữ liệu. Mục 3 trình bày định nghĩa bài toán và phương pháp đề xuất. Mục 4 trình bày kết quả thực nghiệm. Mục 5 kết luận bài báo.

2. Dữ liệu

2.1. Nguồn gốc bộ dữ liệu

Bộ dữ liệu sử dụng trong công trình này được lấy từ repository công khai của iCAM-Net [1], một nghiên cứu gần đây về dự đoán quan hệ thảo dược–bệnh sử dụng attention đa kênh và tín hiệu tương tác phân tử. Dữ liệu gốc được ký hiệu là tập TCM (Traditional Chinese Medicine), bao gồm các liên kết giữa thảo dược, hợp chất, protein và bệnh được thu thập từ nhiều cơ sở dữ liệu y sinh học lớn. Việc trích dẫn và sử dụng lại bộ dữ liệu này tuân theo điều khoản của bài báo gốc [1].

2.2. Cấu trúc và thống kê dữ liệu

Bộ dữ liệu TCM sau khi tiền xử lý và định dạng lại bao gồm các thành phần chính:

- **Thảo dược (Herb):** 1.008 thảo dược, được lập chỉ mục và lưu trong `herb_index.csv`.
- **Bệnh (Disease):** 10.890 bệnh, được lập chỉ mục và lưu trong `disease_index.csv`.
- **Quan hệ thảo dược–bệnh (H–D):** 2.342.544 cặp tương tác dương tính, được lưu dưới dạng ma trận thưa `R_hd.npz`. Mật độ ma trận tương tác là $\approx 21{,}3\%$.
- **Liên kết thảo dược–hợp chất (H–C):** Tệp `H_C_TCM.csv` chứa các cặp (herbid, cid), cung cấp profile hợp chất cho mỗi thảo dược.
- **Liên kết bệnh–protein (D–P):** Tệp `D_P_TCM.csv` chứa các cặp (diseaseId, geneId), cung cấp profile protein cho mỗi bệnh.
- **Mẫu âm tính:** Được lưu trong `H_D_TCM_neg.csv` để phục vụ đánh giá.

Ma trận tương tác $\mathbf{R} \in \{0,1\}^{1008\times 10890}$ được lưu dạng *sparse matrix* (định dạng `.npz`) để tiết kiệm bộ nhớ. Thống kê chi tiết được tóm tắt trong Bảng 1.

Bảng 1: Thống kê bộ dữ liệu TCM

Thực thể / Quan hệ	**Số lượng**
Số thảo dược (M)	1.008
Số bệnh (N)	10.890
Số cặp tương tác dương tính	2.342.544
Mật độ ma trận $\mathbf{R}$	$\approx 21{,}3\%$
Số hợp chất liên kết với thảo dược	(từ H_C_TCM.csv)
Số protein liên kết với bệnh	(từ D_P_TCM.csv)

2.3. Tiền xử lý dữ liệu

Quá trình tiền xử lý bao gồm: (i) đọc và chuẩn hóa các ID thảo dược và bệnh thành chỉ số nguyên liên tiếp; (ii) xây dựng ma trận tương tác thưa $\mathbf{R}$ từ tệp liên kết H–D; (iii) xây dựng profile nhị phân cho thảo dược dựa trên tập hợp chất và cho bệnh dựa trên tập protein mục tiêu. Các profile này được dùng để tính toán độ tương đồng cosine phục vụ xây dựng đồ thị tương tự. Dữ liệu tóm tắt được lưu trong `dataset_summary.json` để phục vụ tái tạo thực nghiệm.

3. Bài toán và Phương pháp Đề xuất

3.1. Định nghĩa bài toán

Đặt $\mathcal{H} = \{h_1, h_2, \ldots, h_M\}$ là tập hợp M thảo dược và $\mathcal{D} = \{d_1, d_2, \ldots, d_N\}$ là tập hợp N bệnh. Ma trận tương tác đã biết $\mathbf{R} \in \{0,1\}^{M\times N}$, trong đó $R_{ij} = 1$ nếu thảo dược h_i có quan hệ với bệnh d_j, ngược lại $R_{ij} = 0$.

Mỗi thảo dược h_i được liên kết với một tập hợp các hợp chất $\mathcal{C}(h_i) \subseteq \mathcal{C}$, và mỗi bệnh d_j được liên kết với một tập hợp các protein $\mathcal{P}(d_j) \subseteq \mathcal{P}$, với $\mathcal{C}$ là không gian hợp chất và $\mathcal{P}$ là không gian protein mục tiêu.

Bài toán dự đoán HDA được định nghĩa như sau: cho biết $\mathbf{R}$, $\{\mathcal{C}(h_i)\}_{i=1}^{M}$, $\{\mathcal{P}(d_j)\}_{j=1}^{N}$, học hàm dự đoán:

$$f : \mathcal{H} \times \mathcal{D} \to [0,1] \tag{1}$$

sao cho $f(h_i, d_j)$ xấp xỉ xác suất tồn tại quan hệ giữa h_i và d_j. Các cặp (h_i, d_j) với $R_{ij} = 0$ và điểm số cao được coi là ứng viên quan hệ mới tiềm năng.

3.2. Kiến trúc tổng thể

Kiến trúc tổng thể của phương pháp đề xuất được minh họa trong Hình 1. Mô hình bao gồm bốn mô-đun chính: (1) xây dựng đồ thị đôi (dual graph construction) từ ma trận tương tác và profile sinh học; (2) encode biểu diễn bằng GAT ba lớp trên từng đồ thị; (3) kết hợp hai luồng biểu diễn thông qua fused attention; và (4) tính điểm cặp và tối ưu hóa

với hàm mất mát tổng hợp gồm BCE loss, contrastive pair loss và dual-view contrastive loss.

3.3. Xây dựng đồ thị

Mô hình xây dựng hai loại đồ thị trên tập nút $\mathcal{V} = \mathcal{H} \cup \mathcal{D}$ với $|\mathcal{V}| = M + N$ nút, trong đó nút thứ i với $i < M$ đại diện cho thảo dược h_i, và nút thứ $M + j$ đại diện cho bệnh d_j.

3.3.1. Đồ thị tương tác (Adjacency Graph)

Đồ thị $\mathcal{G}_{\text{adj}} = (\mathcal{V}, \mathcal{E}_{\text{adj}})$ mã hóa các tương tác đã biết từ ma trận $\mathbf{R}$. Với mỗi cặp (h_i, d_j) thỏa $R_{ij} = 1$, hai cạnh vô hướng $(v_{h_i} \leftrightarrow v_{d_j})$ được tạo ra (biểu diễn dưới dạng hai cạnh có hướng ngược chiều). Để kiểm soát kích thước đồ thị, số lượng cạnh dương tính được giới hạn bởi ngưỡng `graph_pos_edge_cap`; nếu vượt quá, các cạnh được chọn ngẫu nhiên không lặp lại.

3.3.2. Đồ thị Tương tự (Similarity Graph)

Đồ thị $\mathcal{G}_{\text{sim}} = (\mathcal{V}, \mathcal{E}_{\text{sim}})$ mã hóa độ tương đồng sinh học giữa các thảo dược với nhau và giữa các bệnh với nhau. Để xây dựng đồ thị này, mô hình kết hợp hai loại độ tương đồng.

Tương đồng dựa trên profile: Vector profile nhị phân của thảo dược h_i được định nghĩa là:

$$\mathbf{p}_i^h = \big[\mathbf{1}[c \in \mathcal{C}(h_i)]\big]_{c \in \mathcal{C}} \in \{0,1\}^{|\mathcal{C}|} \tag{2}$$

trong đó $\mathbf{1}[\cdot]$ là hàm chỉ thị. Độ tương đồng cosine giữa thảo dược h_i và h_k là:

$$s_{ik}^h = \frac{\mathbf{p}_i^h \cdot \mathbf{p}_k^h}{\|\mathbf{p}_i^h\| \cdot \|\mathbf{p}_k^h\|} \tag{3}$$

Tương tự, vector profile của bệnh d_j là $\mathbf{p}_j^d \in \{0,1\}^{|\mathcal{P}|}$ (dựa trên tập protein mục tiêu), và độ tương đồng s_{jl}^d được tính theo cosine trên protein profile.

Tương đồng Gaussian Interaction Profile (GIP): GIP [8] khai thác cấu trúc hàng/cột của ma trận tương tác để đo lường độ tương đồng. Đối với thảo dược:

$$\text{GIP}_{ik}^h = \exp\big(-\gamma_h \|\mathbf{r}_{h_i} - \mathbf{r}_{h_k}\|^2\big) \tag{4}$$

trong đó $\mathbf{r}_{h_i}$ là hàng thứ i của $\mathbf{R}$ (vector tương tác của thảo dược h_i với tất cả các bệnh), và γ_h là hệ số chuẩn hóa:

$$\gamma_h = \frac{1}{\mathbb{E}_i[\|\mathbf{r}_{h_i}\|^2]} \tag{5}$$

GIP của bệnh GIP_{jl}^d được tính tương tự trên cột của $\mathbf{R}$ (vector tương tác của bệnh d_j với tất cả các thảo dược).

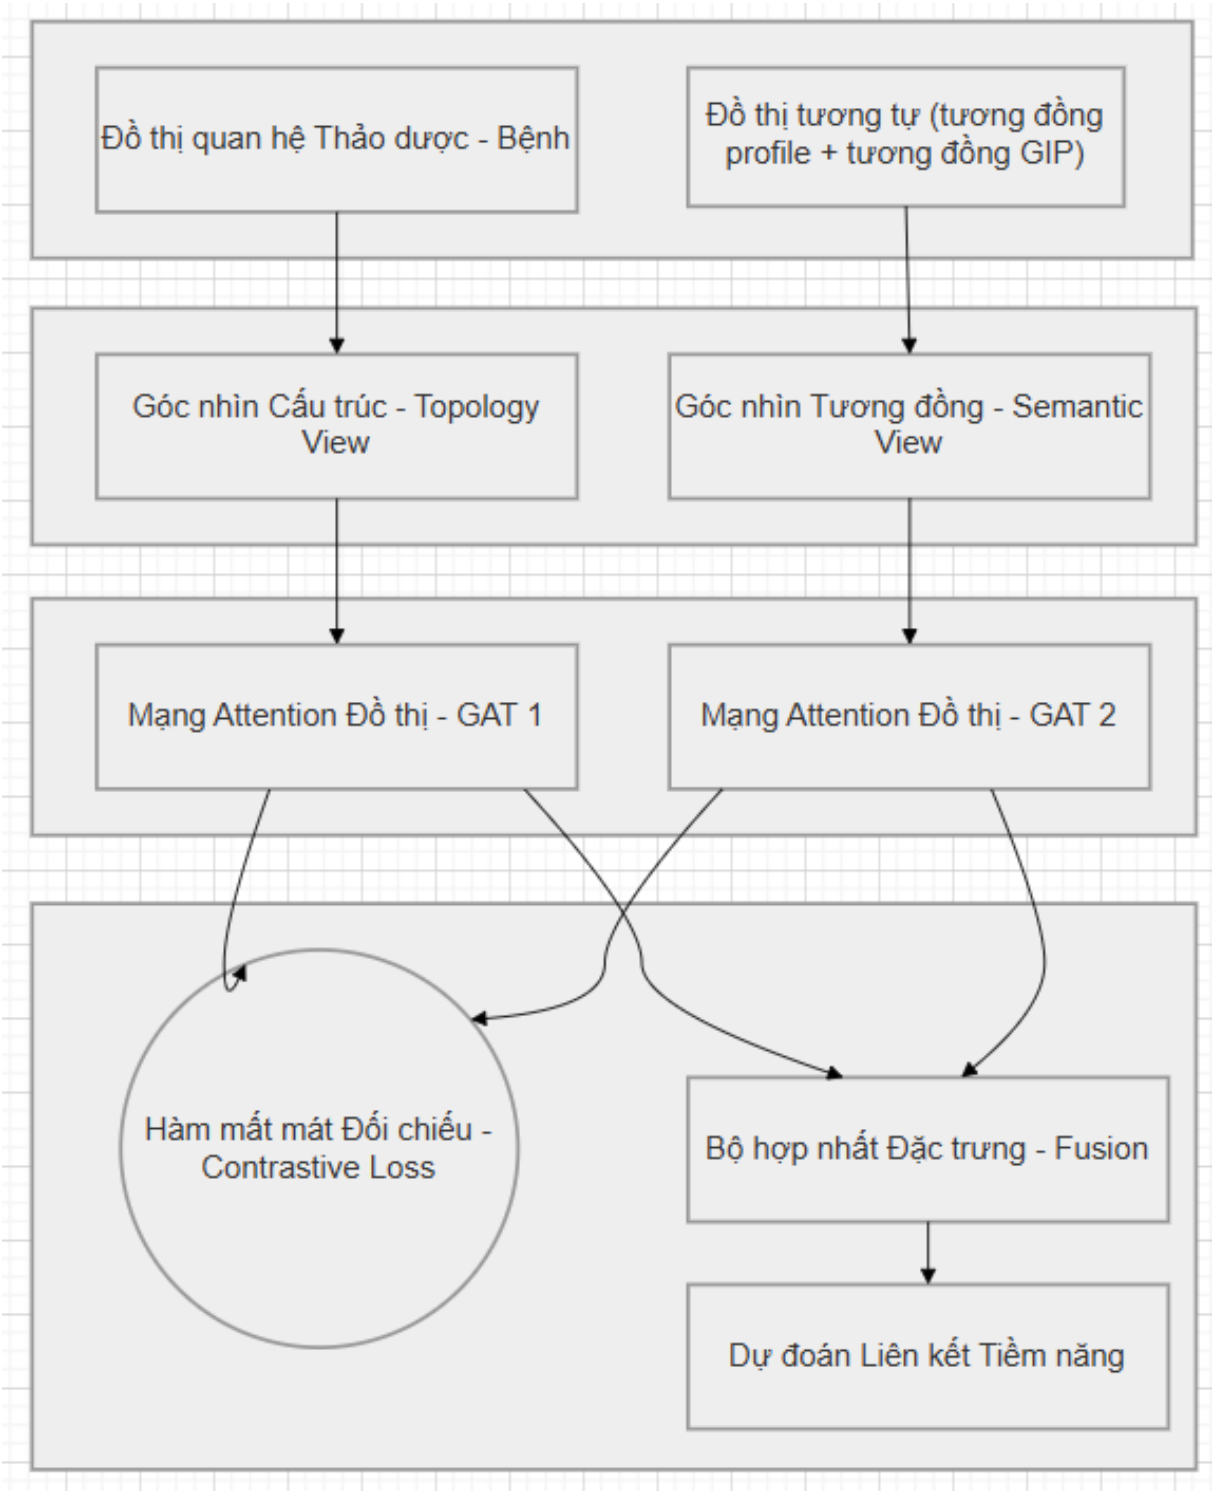

Hình 1: Kiến trúc tổng thể của mô hình GATHDA-DVCL.

Độ tương đồng kết hợp: Độ tương đồng cuối cùng giữa hai thảo dược được tính là trung bình có trọng số:

$$\tilde{s}_{ik}^{h} = \alpha \cdot s_{ik}^{h} + (1-\alpha) \cdot \mathrm{GIP}_{ik}^{h}, \quad \alpha = 0{,}5 \tag{6}$$

Tương tự, $\tilde{s}_{jl}^{d}$ là độ tương đồng kết hợp giữa hai bệnh. Các cạnh tương tự trong $\mathcal{G}_{\text{sim}}$ được xây dựng bằng thuật toán k-nearest neighbor (k-NN) với trọng số $\tilde{s}_{ik}^{h}$ (cho thảo dược) và $\tilde{s}_{jl}^{d}$ (cho bệnh). Tham số k kiểm soát mật độ của đồ thị tương tự và được xác định qua quá trình tuning.

3.4. Mô hình Graph Attention Network

Mỗi nút $v \in \mathcal{V}$ được khởi tạo với một embedding học được $\mathbf{x}_v \in \mathbb{R}^{d_e}$ thông qua lớp nhúng $\mathbf{E} \in \mathbb{R}^{(M+N)\times d_e}$, với d_e là số chiều embedding nút. Lớp nhúng này là tham số có thể học trong quá trình huấn luyện.

Mô hình GAT gồm $L = 3$ lớp. Tại lớp l, biểu diễn nút v được cập nhật bằng:

$$\mathbf{h}_v^{(l)} = \sigma\left(\sum_{u \in \mathcal{N}(v)\cup\{v\}} \alpha_{vu}^{(l)} \cdot \mathbf{W}^{(l)} \mathbf{h}_u^{(l-1)}\right) \tag{7}$$

trong đó $\mathbf{h}_v^{(0)} = \mathbf{x}_v$ là biểu diễn ban đầu, $\mathcal{N}(v)$ là tập hàng xóm của nút v, $\mathbf{W}^{(l)} \in \mathbb{R}^{d_h \times d_h}$ là ma trận trọng số học được tại lớp l, σ là hàm kích hoạt ELU, và $\alpha_{vu}^{(l)}$ là hệ số attention.

Hệ số attention $\alpha_{vu}^{(l)}$ được tính theo cơ chế attention của GAT [5]:

$$e_{vu}^{(l)} = \mathrm{LeakyReLU}\big(\mathbf{a}^{(l)\top}\left[\mathbf{W}^{(l)}\mathbf{h}_v^{(l-1)} \,\|\, \mathbf{W}^{(l)}\mathbf{h}_u^{(l-1)}\right]\big) \tag{8}$$

$$\alpha_{vu}^{(l)} = \frac{\exp\left(e_{vu}^{(l)}\right)}{\sum_{w \in \mathcal{N}(v)\cup\{v\}} \exp\left(e_{vw}^{(l)}\right)} \tag{9}$$

trong đó $\mathbf{a}^{(l)} \in \mathbb{R}^{2d_h}$ là vector attention học được, và $\|$ là phép nối (concatenation). Trọng số cạnh e_{vu} (từ đồ thị đầu vào) được nhân vào hệ số attention trước khi chuẩn hóa softmax, cho phép tích hợp thông tin cường độ cạnh vào cơ chế attention.

Sau ba lớp GAT, đầu ra của lớp thứ ba là biểu diễn nút cuối cùng. Mô hình thực hiện encode trên cả hai đồ thị:

$$\mathbf{Z}_{\text{adj}} = \mathrm{GAT}(\mathcal{G}_{\text{adj}};\, \mathbf{E}) \in \mathbb{R}^{(M+N)\times d_{\text{out}}} \tag{10}$$

$$\mathbf{Z}_{\text{sim}} = \mathrm{GAT}(\mathcal{G}_{\text{sim}};\, \mathbf{E}) \in \mathbb{R}^{(M+N)\times d_{\text{out}}} \tag{11}$$

trong đó hai lần encode chia sẻ cùng một bộ tham số embedding $\mathbf{E}$ nhưng dùng trọng số GAT riêng biệt.

3.5. Kết hợp Hai Góc Nhìn với Fused Attention

Thay vì kết hợp cố định (ví dụ trung bình cộng), mô hình học một cổng attention thích nghi theo từng nút để tổng hợp $\mathbf{Z}_{\text{adj}}$ và $\mathbf{Z}_{\text{sim}}$. Cụ thể, với mỗi nút v, vector trọng số attention được tính:

$$\boldsymbol{\beta}_v = \text{softmax}\big(\mathbf{W}_g \cdot \text{ELU}\big(\mathbf{W}_f \left[\mathbf{z}_v^{\text{adj}} \,\|\, \mathbf{z}_v^{\text{sim}}\right]\big)\big) \in \mathbb{R}^2 \tag{12}$$

trong đó $\mathbf{W}_f \in \mathbb{R}^{d_{\text{out}} \times 2d_{\text{out}}}$ và $\mathbf{W}_g \in \mathbb{R}^{2 \times d_{\text{out}}}$ là các ma trận trọng số học được, $\mathbf{z}_v^{\text{adj}}$ và $\mathbf{z}_v^{\text{sim}}$ là hàng tương ứng với nút v trong $\mathbf{Z}_{\text{adj}}$ và $\mathbf{Z}_{\text{sim}}$.

Biểu diễn tổng hợp sau fused attention:

$$\mathbf{z}_v^{\text{fused}} = \beta_{v,1} \cdot \mathbf{z}_v^{\text{adj}} + \beta_{v,2} \cdot \mathbf{z}_v^{\text{sim}} \tag{13}$$

Cơ chế này cho phép mỗi nút tự động điều chỉnh mức độ tin tưởng vào từng góc nhìn đồ thị tùy thuộc vào đặc trưng của nó. Sau đó, biểu diễn được chiếu riêng biệt cho thảo dược và bệnh qua hai lớp tuyến tính:

$$\mathbf{z}_i^h = \mathbf{W}_h \, \mathbf{z}_{h_i}^{\text{fused}}, \quad \mathbf{z}_j^d = \mathbf{W}_d \, \mathbf{z}_{d_j}^{\text{fused}} \tag{14}$$

với $\mathbf{W}_h, \mathbf{W}_d \in \mathbb{R}^{d_{\text{out}} \times d_{\text{out}}}$ là các ma trận chiếu học được.

3.6. Tính Điểm Cặp

Điểm số liên kết cho cặp (h_i, d_j) được tính bằng tích vô hướng (dot product) của hai biểu diễn sau chiếu, sau đó đưa qua hàm sigmoid:

$$\hat{y}_{ij} = \sigma\big(\mathbf{z}_i^h \cdot \mathbf{z}_j^d\big) = \frac{1}{1 + \exp\big(-\mathbf{z}_i^h \cdot \mathbf{z}_j^d\big)} \tag{15}$$

trong đó $\hat{y}_{ij} \in (0, 1)$ xấp xỉ xác suất tồn tại quan hệ giữa h_i và d_j.

3.7. Hàm Mất mát Tổng hợp

Mô hình được tối ưu hóa bằng hàm mất mát tổng hợp gồm ba thành phần:

3.7.1. Binary Cross-Entropy Loss

Thành phần cơ bản là binary cross-entropy (BCE) trên mini-batch $\mathcal{B}$:

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{|\mathcal{B}|} \sum_{(i,j) \in \mathcal{B}} \left[y_{ij} \log \hat{y}_{ij} + (1 - y_{ij}) \log(1 - \hat{y}_{ij}) \right] \tag{16}$$

trong đó $y_{ij} \in \{0, 1\}$ là nhãn thực và $\hat{y}_{ij}$ là điểm dự đoán từ Phương trình (15).

3.7.2. Contrastive Pair Loss

Để tăng cường khả năng phân biệt biểu diễn giữa các cặp dương tính, mô hình áp dụng contrastive pair loss [6] trên tập hợp các cặp dương tính trong mini-batch:

$$\mathcal{P}_{\mathcal{B}} = \{(i, j) \in \mathcal{B} : y_{ij} = 1\} \tag{17}$$

Nếu $|\mathcal{P}_{\mathcal{B}}| > P_{\max}$, lấy ngẫu nhiên $P_{\max}$ cặp. Chuẩn hóa L_2 các biểu diễn:

$$\tilde{\mathbf{z}}_i^h = \frac{\mathbf{z}_i^h}{\|\mathbf{z}_i^h\|_2}, \quad \tilde{\mathbf{z}}_j^d = \frac{\mathbf{z}_j^d}{\|\mathbf{z}_j^d\|_2} \tag{18}$$

Xây dựng ma trận similarity:

$$\mathbf{S} = \frac{\tilde{\mathbf{Z}}^h \cdot \tilde{\mathbf{Z}}^{d\top}}{\tau_c} \in \mathbb{R}^{|\mathcal{P}'_{\mathcal{B}}| \times |\mathcal{P}'_{\mathcal{B}}|} \tag{19}$$

trong đó $\tilde{\mathbf{Z}}^h$, $\tilde{\mathbf{Z}}^d$ là các ma trận chứa embedding normalized của thảo dược và bệnh trong $\mathcal{P}'_{\mathcal{B}}$ (tập dương tính đã lọc), và τ_c là nhiệt độ (temperature). Hàm mất mát dạng InfoNCE đối xứng:

$$\mathcal{L}_{\text{CPL}} = \frac{1}{2}\left[\mathcal{L}_{\text{CE}}(\mathbf{S}, \mathbf{I}) + \mathcal{L}_{\text{CE}}(\mathbf{S}^\top, \mathbf{I})\right] \tag{20}$$

trong đó $\mathcal{L}_{\text{CE}}(\mathbf{S}, \mathbf{I})$ là cross-entropy với nhãn là đường chéo chính (mỗi cặp dương tính là nhãn đúng của chính nó), tức là mỗi thảo dược h_i cần nhận ra đúng bệnh d_j của mình trong tập dương tính và ngược lại.

3.7.3. Dual-View Contrastive Loss

Thành phần này ép hai luồng biểu diễn từ hai đồ thị nhất quán với nhau ở cấp độ nút [7]. Nếu số nút $|\mathcal{V}| > N_{\max}$, lấy ngẫu nhiên $N_{\max}$ nút. Chuẩn hóa L_2:

$$\tilde{\mathbf{Z}}_{\text{adj}} = \text{normalize}(\mathbf{Z}_{\text{adj}}), \quad \tilde{\mathbf{Z}}_{\text{sim}} = \text{normalize}(\mathbf{Z}_{\text{sim}}) \tag{21}$$

Ma trận similarity giữa hai góc nhìn:

$$\mathbf{Q} = \frac{\tilde{\mathbf{Z}}_{\text{adj}} \cdot \tilde{\mathbf{Z}}_{\text{sim}}^\top}{\tau_d} \in \mathbb{R}^{N' \times N'} \tag{22}$$

trong đó N' là số nút được lấy mẫu và τ_d là nhiệt độ cho dual-view. Hàm mất mát InfoNCE đối xứng giữa hai góc nhìn:

$$\mathcal{L}_{\text{DVL}} = \frac{1}{2}\left[\mathcal{L}_{\text{CE}}(\mathbf{Q}, \mathbf{I}) + \mathcal{L}_{\text{CE}}(\mathbf{Q}^\top, \mathbf{I})\right] \tag{23}$$

Ý nghĩa: nút thứ k trong góc nhìn adjacency phải nhận ra chính nó (nút thứ k) trong góc nhìn similarity, nghĩa là hai biểu diễn của cùng một nút từ hai đồ thị khác nhau phải nhất quán với nhau.

3.7.4. Hàm Mất mát Tổng hợp

Hàm mất mát cuối cùng:

$$\mathcal{L} = \mathcal{L}_{\text{BCE}} + \lambda_c \cdot \mathcal{L}_{\text{CPL}} + \lambda_d \cdot \mathcal{L}_{\text{DVL}} \tag{24}$$

trong đó $\lambda_c > 0$ và $\lambda_d > 0$ là các hệ số cân bằng được xác định qua quá trình tuning. Hàm mất mát tổng hợp này cho phép mô hình đồng thời: (i) tối ưu hóa bài toán phân loại cặp qua $\mathcal{L}_{\text{BCE}}$; (ii) tăng cường biểu diễn phân biệt qua $\mathcal{L}_{\text{CPL}}$; và (iii) đảm bảo nhất quán đa góc nhìn qua $\mathcal{L}_{\text{DVL}}$.

3.8. Huấn luyện

Mô hình được tối ưu hóa bằng thuật toán Adam [12] với mini-batch gradient descent. Trong mỗi epoch, toàn bộ tập train được xáo trộn và duyệt qua theo từng mini-batch. Với mỗi mini-batch, mô hình thực hiện encode toàn bộ đồ thị một lần, sau đó tính điểm và mất mát trên tập cặp trong batch. Kỹ thuật Automatic Mixed Precision (AMP) được sử dụng khi có GPU để tăng tốc và giảm bộ nhớ. Early stopping được áp dụng dựa trên AUPR trên tập validation: nếu AUPR không cải thiện sau `patience` epoch liên tiếp, quá trình huấn luyện dừng lại.

4. Thực nghiệm và Kết quả

4.1. Cài đặt Thực nghiệm

4.1.1. Giao thức đánh giá

Mô hình được đánh giá theo giao thức 5-fold cross-validation. Trong mỗi fold, tập dữ liệu được chia thành tập train, validation và test với tỉ lệ xấp xỉ 70:15:15. Trong mỗi fold, mẫu âm tính được lấy ngẫu nhiên với tỉ lệ 1:1 so với mẫu dương tính để đảm bảo cân bằng lớp. Các chỉ số đánh giá bao gồm: Accuracy (ACC), F1-score, Precision, Recall, AUPR (Area Under Precision-Recall Curve), và AUC (Area Under ROC Curve). Kết quả báo cáo là trung bình và độ lệch chuẩn qua 5 fold.

4.1.2. Siêu tham số

Sau khi tuning, cấu hình tối ưu của mô hình gồm: số chiều embedding nút $d_e = 96$, số chiều ẩn $d_h = 96$, số chiều đầu ra $d_{\text{out}} = 64$, số head attention $n_{\text{heads}} = 2$, tham số $k = 20$

cho k-NN, learning rate $\eta = 10^{-3}$, weight decay $= 10^{-5}$, batch size = 24.576, nhiệt độ contrastive $\tau_c = \tau_d = 0{,}2$, hệ số $\lambda_c = 0{,}08$, $\lambda_d = 0{,}22$, $P_{\max} = 1.536$, $N_{\max} = 6.144$. Số epoch tối đa là 500, early stopping patience là 30. Mô hình được triển khai bằng PyTorch [10] và PyTorch Geometric [11].

4.2. Ablation Study

Để đánh giá đóng góp của từng thành phần, chúng tôi thiết kế năm biến thể:

- **Baseline**: Chỉ sử dụng đồ thị tương tác $\mathcal{G}_{\text{adj}}$, không có GIP similarity, không có contrastive loss, không có fused attention.
- **Extra only**: Thêm đồ thị tương tự $\mathcal{G}_{\text{sim}}$ với GIP (kết hợp trung bình đơn giản, không dual-view CL).
- **Dual-view only**: Thêm dual-view contrastive loss $\mathcal{L}_{\text{DVL}}$, nhưng không sử dụng fused attention (kết hợp trung bình).
- **Attention only**: Sử dụng fused attention để kết hợp hai góc nhìn, nhưng không có dual-view CL.
- **Full proposed**: Kết hợp đầy đủ tất cả thành phần: $\mathcal{G}_{\text{adj}}$, $\mathcal{G}_{\text{sim}}$, fused attention, $\mathcal{L}_{\text{CPL}}$, $\mathcal{L}_{\text{DVL}}$.

Bảng 2: Kết quả Ablation Study (trung bình 5-fold cross-validation)

Cấu hình	**ACC**	**F1**	**Prec.**	**Rec.**	**AUPR**	**AUC**
Baseline	0,8421	0,8466	0,8233	0,8712	0,9194	0,9240
Extra only	0,8643	0,8667	0,8516	0,8824	0,9363	0,9404
Dual-view only	0,8953	0,8966	0,8856	0,9080	0,9624	0,9624
Attention only	0,8911	0,8924	0,8825	0,9024	0,9603	0,9604
Full proposed	**0,9148**	**0,9153**	**0,9099**	**0,9208**	**0,9739**	**0,9741**

Kết quả trong Bảng 2 cho thấy một số nhận xét quan trọng. Thứ nhất, việc bổ sung đồ thị tương tự GIP (Extra only) cải thiện AUPR thêm 1,69 điểm phần trăm so với Baseline, cho thấy thông tin tương đồng sinh học bổ sung đáng kể cho thông tin tương tác trực tiếp. Thứ hai, dual-view contrastive learning (Dual-view only) mang lại bước nhảy lớn nhất với AUPR đạt 0,9624, tức tăng 2,61 điểm phần trăm so với Extra only và 4,30 điểm phần trăm so với Baseline. Điều này chứng tỏ việc ép hai biểu diễn từ hai đồ thị nhất quán với nhau giúp cải thiện đáng kể chất lượng embedding. Thứ ba, cơ chế fused attention (Attention only) đạt AUPR = 0,9603, thấp hơn Dual-view only, nhưng khi kết hợp cả hai trong Full proposed, mô hình đạt kết quả cao nhất AUPR = 0,9739, tăng 5,45 điểm phần trăm so với Baseline. Kết quả này xác nhận tính bổ trợ của các thành phần:

dual-view CL cải thiện chất lượng biểu diễn từng góc nhìn, trong khi fused attention giúp tổng hợp thích nghi hai luồng biểu diễn.

4.3. Tuning Siêu tham số

Quá trình tuning được thực hiện theo chiến lược tuần tự: (1) tìm k tối ưu với $\lambda_c = 0{,}12$ cố định; (2) tìm λ_c tối ưu với k đã chọn. Tiêu chí chọn là cặp (mean AUPR, mean AUC) lớn hơn.

Bảng 3: Kết quả Tuning Siêu tham số (trung bình 5-fold)

k	λ_c	Acc	F1	AUPR	AUC
20	0,08	**0,9148**	**0,9153**	**0,9739**	**0,9741**
20	0,12	0,9008	0,9016	0,9662	0,9661
20	0,16	0,9008	0,9018	0,9661	0,9660
15	0,12	0,9011	0,9020	0,9659	0,9660
20	0,08	0,8995	0,9006	0,9652	0,9652
25	0,12	0,8972	0,8983	0,9642	0,9641
30	0,12	0,8947	0,8956	0,9623	0,9623
35	0,12	0,8903	0,8914	0,9600	0,9600
40	0,12	0,8897	0,8912	0,9596	0,9597

Bảng 3 cho thấy một số xu hướng rõ ràng. Về tham số k: giá trị $k = 20$ cho kết quả tốt nhất trong số các giá trị được thử nghiệm ($k \in \{15, 20, 25, 30, 35, 40\}$). Khi k tăng lên, AUPR có xu hướng giảm dần (từ 0,9662 với $k = 20$ xuống 0,9596 với $k = 40$), cho thấy việc thêm quá nhiều hàng xóm vào đồ thị tương tự có thể đưa vào các cạnh nhiễu, làm giảm chất lượng biểu diễn. Về tham số λ_c: giá trị $\lambda_c = 0{,}08$ nhỏ hơn giá trị mặc định 0,12 lại cho AUPR cao hơn đáng kể (0,9739 so với 0,9662), gợi ý rằng contrastive pair loss quá mạnh có thể gây nhiễu cho quá trình tối ưu hóa phân loại.

4.4. So sánh với một số phương pháp khác

Bảng 4: So sánh với một số phương pháp khác trên bộ dữ liệu TCM (5-fold cross-validation)

Phương pháp	**AUPR**	**AUC**
MNNMDA [3]	0,8943	0,9012
NCP [2]	0,9201	0,9253
iCAM-Net [1]	0,9412	0,9438
GATHDA-DVCL (đề xuất)	**0,9739**	**0,9741**

Bảng 4 so sánh mô hình đề xuất với ba phương pháp tiêu biểu trên bộ dữ liệu TCM, xét trên hai chỉ số AUPR và AUC (các phương pháp so sánh được cài đặt lại từ các bài

báo gốc của tác giả). MNNMDA [3] là phương pháp dựa trên matrix factorization kết hợp đa mạng, đạt AUPR = 0,8943. NCP [2] là phương pháp dựa trên network consistency projection, khai thác thông tin tương đồng để suy diễn liên kết, đạt AUPR = 0,9201. iCAM-Net [1], mô hình nguồn gốc của bộ dữ liệu, sử dụng cơ chế attention đa kênh và tín hiệu tương tác phân tử, đạt AUPR = 0,9412 và là phương pháp mạnh nhất trong số các baseline.

So với iCAM-Net, mô hình đề xuất cải thiện 3,27 điểm phần trăm về AUPR và 3,03 điểm phần trăm về AUC. Những kết quả này cho thấy việc kết hợp dual-view contrastive learning với cơ chế fused attention trong kiến trúc GAT giúp khai thác hiệu quả thông tin đa góc nhìn và nâng cao chất lượng biểu diễn, từ đó cải thiện đáng kể hiệu năng dự đoán quan hệ thảo dược–bệnh.

4.5. Đường cong PR và ROC

Hình 2 và Hình 3 lần lượt trình bày đường cong Precision-Recall và đường cong ROC của mô hình đề xuất qua 5 fold trên tập kiểm tra. Diện tích lớn dưới đường cong PR (AUPR = 0,9739) cho thấy mô hình duy trì độ chính xác cao khi tăng ngưỡng recall, điều đặc biệt quan trọng trong ứng dụng y sinh học nơi tỉ lệ âm tính giả (false negative) cần được kiểm soát. Đường cong ROC với AUC = 0,9741 cũng xác nhận khả năng phân biệt mạnh của mô hình giữa các cặp dương tính và âm tính thực sự. Độ lệch chuẩn thấp giữa các fold (std AUPR = 0,0006, std AUC = 0,0006) cho thấy mô hình ổn định và không bị overfit trên một fold cụ thể.

4.6. Phân tích mối tương quan giữa mức độ kết nối và độ tự tin dự đoán

Một trong những ứng dụng quan trọng nhất của mạng nơ-ron đồ thị trong mạng lý dược học là khả năng phát hiện các công dụng điều trị mới của thảo dược (Herb Repurposing). Để đánh giá năng lực này, chúng tôi tiến hành trích xuất và phân tích các liên kết chưa từng được ghi nhận trong tập dữ liệu (unobserved edges/negative pairs) đối với ba nút thảo dược có mức độ kết nối cao nhất (nút 3535, 4615 và 4842).

Hình 4 minh họa mối tương quan giữa bậc của nút (đại diện cho phổ tác dụng rộng của thảo dược) và độ tự tin của mô hình khi dự đoán các liên kết mới. Đối với các nút trung tâm (hub nodes) mang lượng thông tin đặc trưng đồ thị lớn, mô hình thể hiện khả năng nội suy mạnh mẽ, đưa ra các dự đoán tiềm năng với xác suất cực kỳ cao (vượt ngưỡng 0.998). Thay vì bị nhiễu loạn bởi không gian mẫu âm tính khổng lồ, kiến trúc Dual-View Contrastive Learning giúp mô hình chắt lọc được những ứng viên bệnh lý có độ tương đồng không gian ẩn sát nhất với phổ điều trị của thảo dược.

Việc đánh giá sự thay đổi của độ tự tin dự đoán trên Top-10 liên kết mới (Hình 5) cung cấp góc nhìn sâu sắc về khả năng xếp hạng phân biệt của mô hình. Biểu đồ cho thấy một sự chuyển biến xác suất rất tinh tế. Đối với nút 4615, đồ thị đi ngang duy trì độ tự

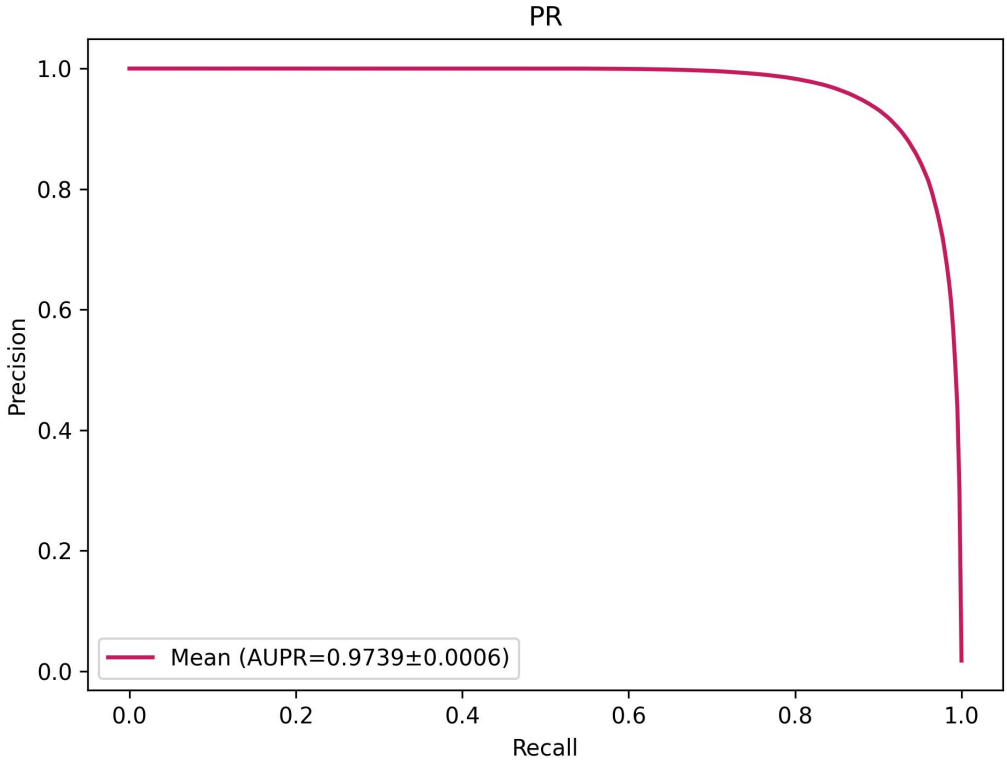

Hình 2: Đường cong Precision-Recall (PR curve) của mô hình GATHDA-DVCL qua 5-fold cross-validation.

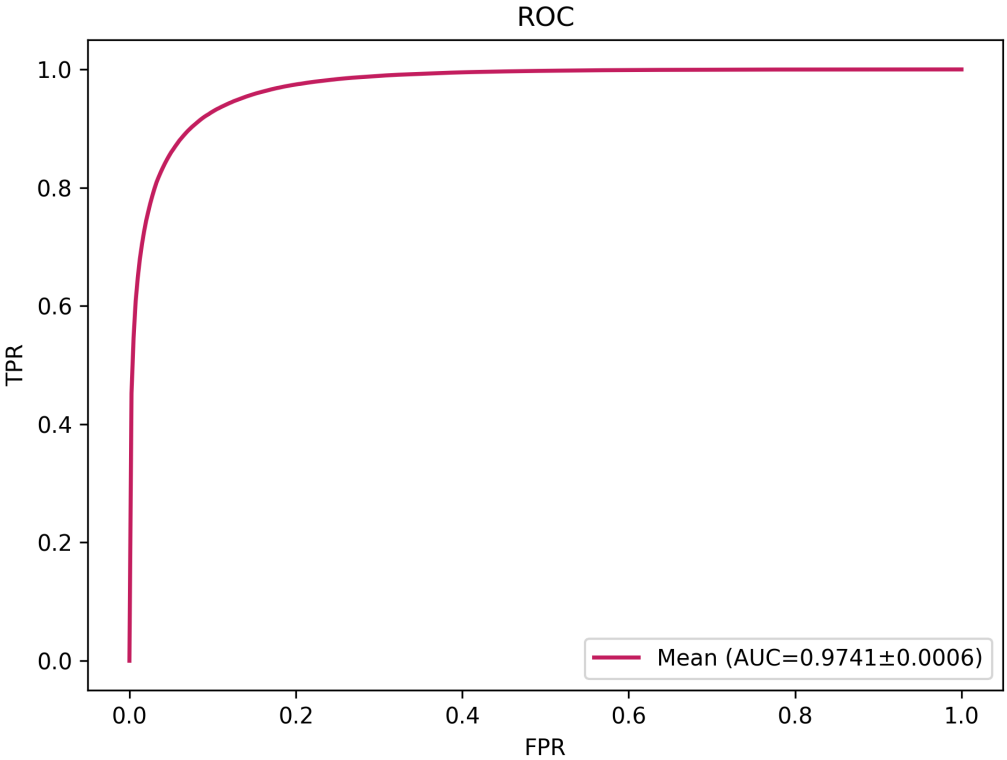

Hình 3: Đường cong ROC của mô hình GATHDA-DVCL qua 5-fold cross-validation.

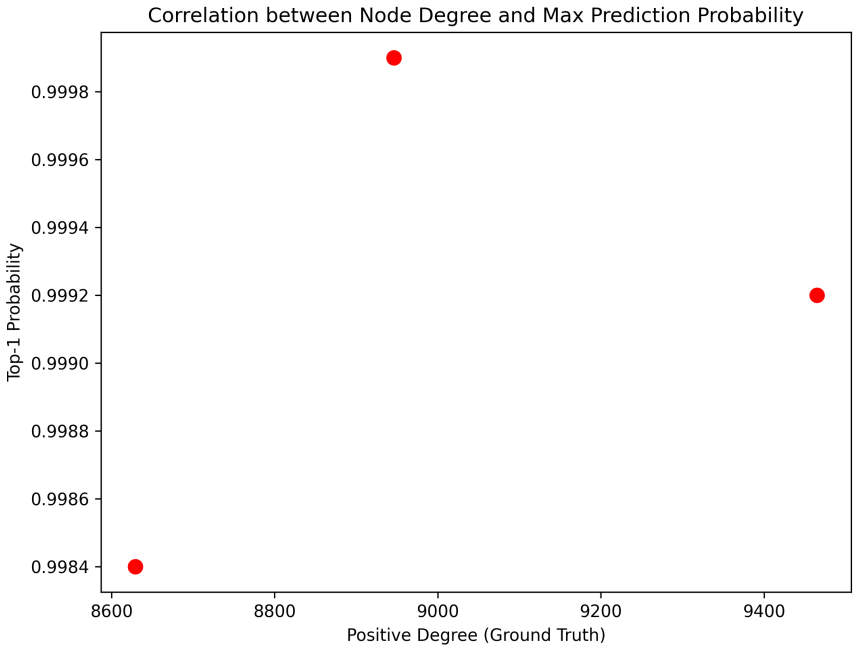

Hình 4: Mối tương quan giữa mức độ kết nối của thảo dược và xác suất dự đoán cao nhất (Top-1) cho các liên kết bệnh lý chưa được khám phá.

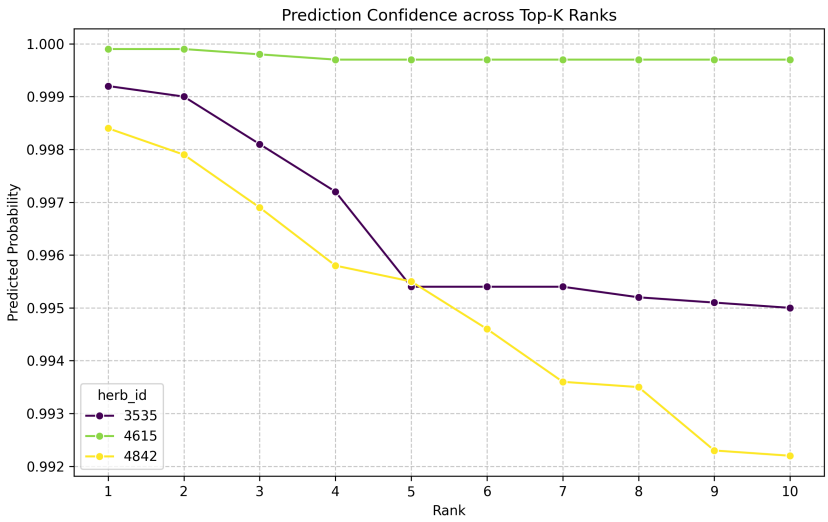

Hình 5: Sự suy giảm xác suất dự đoán trên Top-10 liên kết tiềm năng mới của ba thảo dược có mật độ kết nối cao nhất.

tin tiệm cận tuyệt đối, gợi ý rằng 10 bệnh lý này có thể thuộc cùng một nhóm triệu chứng hoặc cơ sở bệnh sinh mà thảo dược này tác động mạnh. Ngược lại, nút 4842 cho thấy sự phân hóa rõ ràng hơn khi độ tự tin giảm tuyến tính từ 0.9984 xuống 0.9922. Sự suy giảm có kiểm soát này chứng minh rằng mô hình không gán trọng số một cách cực đoan cho toàn bộ các cạnh âm tính lân cận, mà thực sự thực hiện việc đánh giá (scoring) dựa trên chất lượng của từng cặp đặc trưng Thảo dược - Bệnh. Các dự đoán có xác suất cao này mở ra hướng đi đầy hứa hẹn cho các nghiên cứu kiểm chứng lâm sàng trong tương lai.

5. Kết luận

Bài báo này đề xuất mô hình GATHDA-DVCL cho bài toán dự đoán quan hệ thảo dược–bệnh trên dữ liệu TCM quy mô lớn. Điểm đặc trưng của mô hình là sự tích hợp có hệ thống bốn thành phần: (i) hai loại đồ thị bổ trợ nhau (đồ thị tương tác và đồ thị tương tự kết hợp GIP) được encode bằng GAT ba lớp; (ii) dual-view contrastive learning đảm bảo nhất quán biểu diễn giữa hai góc nhìn ở cấp độ nút; (iii) contrastive pair loss tăng cường khả năng phân biệt cặp dương tính; và (iv) fused attention kết hợp thích nghi hai luồng biểu diễn theo từng nút.

Ablation study xác nhận đóng góp rõ ràng và có tính bổ trợ của từng thành phần, trong đó dual-view contrastive learning là yếu tố có ảnh hưởng lớn nhất (tăng 4,30 điểm AUPR khi thêm vào). Quá trình tuning siêu tham số theo giai đoạn cho thấy tham số tốt nhất là $k = 20$, $\lambda_c = 0{,}08$, $\lambda_d = 0{,}22$. Mô hình đề xuất đạt AUPR = 0,9739 và AUC = 0,9741, vượt trội so với các phương pháp hiện có trên cùng bộ dữ liệu TCM, trong đó tốt hơn phương pháp mạnh nhất trước đó (hgcl) 1,81 điểm phần trăm AUPR.

Hướng nghiên cứu tương lai bao gồm: (i) mở rộng sang bộ dữ liệu HERB cũng có trong repository để đánh giá tính tổng quát; (ii) tích hợp thêm thông tin cấu trúc phân tử (fingerprint, SMILES) của hợp chất vào quá trình xây dựng đồ thị; (iii) khám phá các chiến lược sampling mẫu âm tính thông minh hơn; và (iv) thiết kế cơ chế giải thích (explainability) để làm rõ tầm quan trọng của từng hợp chất và protein trong các dự đoán cụ thể.

Lời cảm ơn

[Chưa có nội dung, tác giả bổ sung sau.]

Tài liệu

[1] D. Zheng, C. Qin, Z. Wang, Y. Li, Y. Liu, Y. Wang, H. Kan, and J. Hu, "iCAM-Net: Interpretable herb–disease association prediction via cross-channel

attention and molecular interaction signals," *Phytomedicine*, p. 157491, 2025, doi: 10.1016/j.phymed.2025.157491.

[2] Chen L, Zhang S, Zhou B, "Herb-disease association prediction model based on network consistency projection", *Sci Rep.* 2025 Jan 27;15(1):3328. doi: 10.1038/s41598-025-87521-7. PMID: 39865145; PMCID: PMC11770172.

[3] Liu H, Bing P, Zhang M, Tian G, Ma J, Li H, Bao M, He K, He J, He B, Yang J. MNNMDA: Predicting human microbe-disease association via a method to minimize matrix nuclear norm. Comput Struct Biotechnol J. 2023 Jan 2;21:1414-1423. doi: 10.1016/j.csbj.2022.12.053. PMID: 36824227; PMCID: PMC9941872.

[4] T. N. Kipf and M. Welling, "Semi-supervised classification with graph convolutional networks," in *Proc. Int. Conf. Learning Representations (ICLR)*, 2017.

[5] P. Velicković, G. Cucurull, A. Casanova, A. Romero, P. Liò, and Y. Bengio, "Graph attention networks," in *Proc. Int. Conf. Learning Representations (ICLR)*, 2018.

[6] T. Chen, S. Kornblith, M. Norouzi, and G. Hinton, "A simple framework for contrastive learning of visual representations," in *Proc. Int. Conf. Machine Learning (ICML)*, 2020, pp. 1597–1607.

[7] Y. You, T. Chen, Y. Sui, T. Chen, Z. Wang, and Y. Shen, "Graph contrastive learning with augmentations," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020, pp. 5812–5823.

[8] Zhang Y, Wang Y, Wu C, Zhan L, Wang A, Cheng C, Zhao J, Zhang W, Chen J, Li P. Drug-target interaction prediction by integrating heterogeneous information with mutual attention network. BMC Bioinformatics. 2024 Nov 19;25(1):361. doi: 10.1186/s12859-024-05976-3. PMID: 39563226; PMCID: PMC11577831.

[9] Z. Yin, Y. Wu, and Y. Zhang, "HGCL: Heterogeneous Graph Contrastive Learning for Traditional Chinese Medicine Prescription Generation,"in Health Information Science (Lecture Notes in Computer Science), Springer, 2022, pp. 88–99. doi: 10.1007/978-3-031-20627-6-9.

[10] A. Paszke *et al.*, "PyTorch: An imperative style, high-performance deep learning library," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019.

[11] M. Fey and J. E. Lenssen, "Fast graph representation learning with PyTorch Geometric," in *Proc. ICLR Workshop on Representation Learning on Graphs and Manifolds*, 2019.

[12] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," in *Proc. Int. Conf. Learning Representations (ICLR)*, 2015.